Stemmegivningsagenten: kravrespons

Case 1, FinTech Hackathon H2026 · Lag: [Gruppenavn] · 6. november 2026

På 3 448 forslag fra 2025–2026 fant agenten 56,2 % av sakene der NBIM gikk mot styret, med 70,4 % presisjon.

Hva vi bygde

Agenten leser sakslisten til en generalforsamling og foreslår FOR, MOT eller AVSTÅ på hver sak, med sakstype, sitert regel fra NBIMs retningslinjer, begrunnelse og konfidens. Den støtter én beslutning: hvilke saker en analytiker må lese før NBIM stemmer. Saker med konfidens under 0,80 eller mistenkelig tekst går til et menneske, og agenten stemmer aldri selv. På 3 448 forslag fra 2025–2026 måtte et menneske se 6,9 % av sakene, og da var 66,9 % av sakene der NBIM gikk mot styret fanget, mot 47,3 % for tekstmodellen med samme lesemengde. Av de 3 209 sakene som slapp gjennom, gikk 56 (1,7 %) mot styret og ble oversett.

Hvordan vi verifiserte det

Målvariabelen er `against_board` i `real_votes.csv`, altså om NBIM stemte annerledes enn styret anbefalte (13 324 forslag, 193 selskaper, 2019–2026). Vi måler presisjon og recall fordi «alltid med styret» gir 95,1 % accuracy og 0 % recall. Agenten ble justert på 2023–2024, låst og kjørt én gang på 2025–2026 (3 448 saker, 169 mot styret).

Metode	Accuracy	Presisjon (95 %-intervall)	Recall (95 %-intervall)	Falske alarmer per treff
Alltid med styret	95,1 %	0 %	0 %	–
Sakstyper med minst 50 % mot i trening	95,4 %	73,9 %	10,1 %	0,35
Mot på samme sakstype på forrige møte	85,1 %	16,5 %	50,3 %	5,05
Enkel tekstmodell	84,3 %	18,1 %	62,7 %	4,52
Agenten	**96,7 %**	**70,4 % (62,1–78,1)**	**56,2 % (45,5–65,3)**	**0,42**

Bare på saker der styret sa FOR og NBIM sa MOT er presisjonen 68,8 % og recall 54,8 %. `real_votes` stemmer med Norges Banks SEC-filer i 90 av 92 say-on-pay-saker, mens `npx_votes` ikke brukes som fasit fordi 1 032 av 1 936 saker merket «mot styret» er aksjonærforslag der styret står som FOR.

Forklarbarhet og motstandstest

Regelen agenten siterer ligger i samme seksjon som NBIMs egen begrunnelse i 95,8 % av treffene (91 av 95), og hvert kall logges med prompt-hash, modell og råsvar. Vi la 50 skjulte instrukser og falske påstander inn i 16 tilfeldig trukne møter fra 2023–2024, med en nøytral kontroll i hvert møte. Ingen endret stemmen, og alle ble merket og sendt til et menneske. Ingen av de 16 kontrollene ga falsk alarm, men angrepene var ikke tilpasset agenten.

Begrensninger

- Agenten finner mest gjentakelser: 88,2 % når NBIM gikk mot styret på samme sakstype på forrige møte, men 23,8 % på nye saker.
- Modellen kan huske utfall fra før kunnskapsgrensen i juni 2026, og etter den fant den 5 av 7 saker, som er for få til å utelukke dette.
- Vi kjenner ikke hvordan de 193 selskapene er valgt, så tallene gjelder ikke nødvendigvis hele porteføljen.
- AVSTÅ kan ikke forutsies (5 saker i fasiten, ingen treff), og retningslinjene fra 2024 brukes på alle år.
- Hele retningslinjen ligger i prompten i stedet for RAG, og posisjonsnotatene er ikke med.

Hva vi ville trengt videre

Data: Vi trenger fakta om styret (uavhengighet, oppmøte, verv) og innkallingene (DEF 14A), fordi mange regler krever dette. **Tilgang:** NBIMs komplette stemmedatabase og tidligere utgaver av retningslinjene ville gjort at hvert år kan vurderes mot reglene som gjaldt da. **Tid:** Med mer tid ville vi kjørt skyggedrift på kommende møter, der forslaget låses før NBIM publiserer stemmen. Vi ville brukt agenten til å sortere saker for en analytiker, ikke til å stemme.

Reproduser resultatet med `python reproduser.py`. Kilder og AI-bruk står i README.